Entregable 2 - Machine Learning

Predicción de Severidad de Tráfico

Comparación de Modelos de Clasificación Multiclase

Equipo: **Andrés Diaz Arias** & **Sebastian Duque Bañol**

Entendimiento del Problema

Definición del objetivo y exploración del ecosistema de datos.

El Problema a Resolver

El objetivo del proyecto es predecir el **nivel de severidad** de los eventos de congestión de tráfico utilizando datos históricos.

- **Clasificación Multiclase:** La variable objetivo (Severity) clasifica el tráfico en niveles del 0 al 4.
- **Variables Clave:** Ubicación geográfica, tiempo del evento, distancia afectada y métricas de retraso.
- **Volumen de Datos:** Muestra masiva de 2 millones de registros en EE. UU. (2016-2022).
- **Importancia:** Permite optimizar rutas, mejorar la movilidad urbana y reducir riesgos viales.

Exploración de Datos (EDA)

Distribución Desbalanceada

La variable objetivo *Severity* presenta un claro desbalance. Las clases 1 y 2 concentran la inmensa mayoría de los eventos de tráfico.

Por el contrario, los eventos de severidad 3 y especialmente 4 son extremadamente raros (solo 9 casos de nivel 4 en 2M de registros), lo que representa un reto analítico significativo para el entrenamiento de los modelos predictivos.

Relación de Variables

Las variables relacionadas con el tráfico son las más influyentes. Se observó una alta correlación positiva entre *DelayFromTypicalTraffic* y *DelayFromFreeFlowSpeed*.

Además, el diagrama de dispersión evidenció que a mayor distancia afectada en la vía, tiende a registrarse un mayor nivel de retraso y, consecuentemente, un nivel superior de severidad.

Preparación y Limpieza de Datos

Limpieza

Eliminación de columnas irrelevantes (IDs, descripciones). Manejo de valores nulos imputando la media para variables numéricas y el valor "Unknown" para categóricas.

Ingeniería de Características

Transformación de fechas extrayendo componentes temporales vitales como la 'Hora' y el 'Día de la semana' para modelar los patrones de horas pico y días laborales.

Escalado y Codificación

Aplicación de LabelEncoder para variables texto y StandardScaler para numéricas, paso obligatorio para asegurar el correcto funcionamiento de algoritmos sensibles a la distancia como KNN.

Implementación y Evaluación

Desempeño predictivo y comparación métrica de los algoritmos de clasificación.

Métricas de Evaluación de Modelos

MODELO ALGORÍTMICO	ACCURACY	PRECISION (W)	RECALL (W)	F1-SCORE (W)
KNN (K-Nearest Neighbors)	**0.6401**	0.6409	0.6401	**0.6343**
Regresión Logística	0.5726	0.5767	0.5726	0.5574
Naive Bayes (Gaussian)	0.4172	0.4841	0.4172	0.3567
Regresión Lineal	*No aplicable (Problema de clasificación, no continuo)*			

** Métricas calculadas sobre el conjunto de prueba (Test Split). (W) = Weighted Average.*

Comparativa de Exactitud (Accuracy)

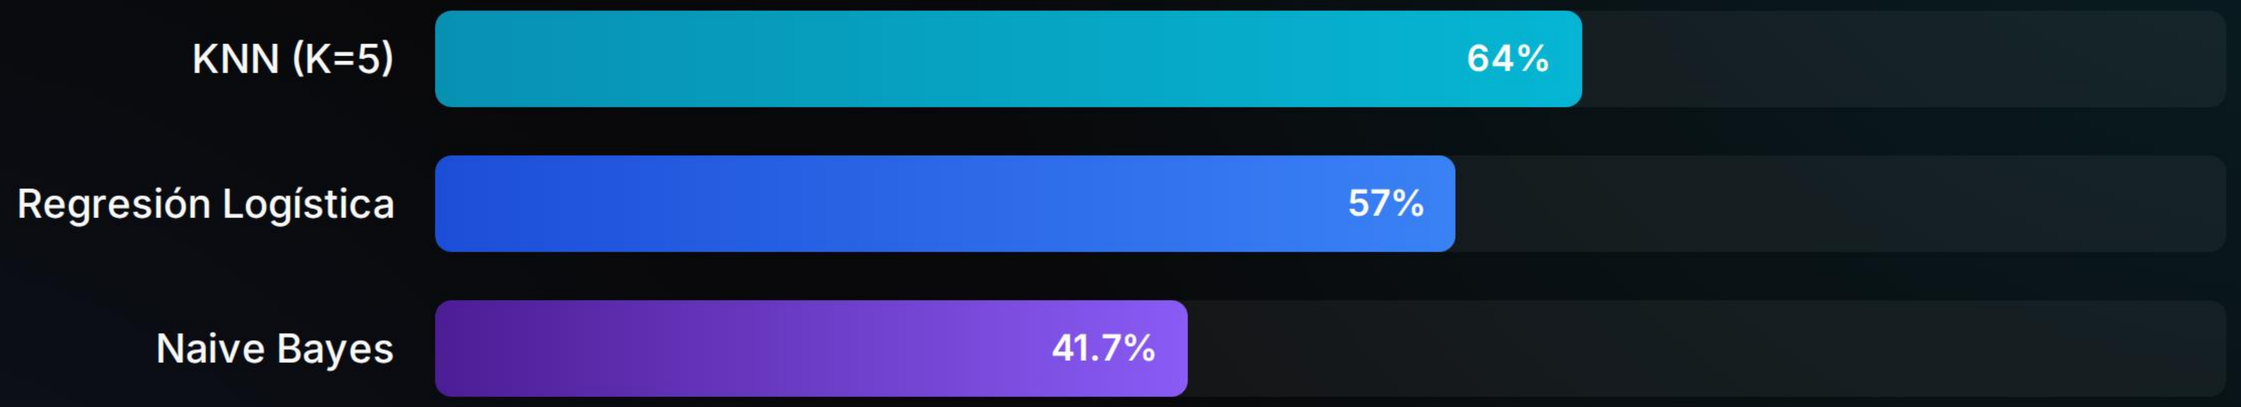

El modelo **KNN presenta la superioridad predictiva** debido a su flexibilidad para modelar relaciones no lineales y complejas en el tráfico. Los modelos más simples, que asumen linealidad o independencia estricta de variables, no logran representar adecuadamente el problema.

Explicación Conceptual

KNN

"Dime con quién andas y te diré quién eres." Clasifica un evento nuevo buscando los 5 eventos pasados más parecidos a él. Es excelente para capturar patrones locales y complejos del mundo real.

Regresión Logística

Busca trazar líneas rectas para separar los diferentes niveles de severidad calculando probabilidades matemáticas. Se queda corto porque los patrones climáticos y de tráfico rara vez son simples líneas rectas.

Naive Bayes

Calcula probabilidades asumiendo que todas las variables son 100% independientes. Falla drásticamente porque en la vida real, el tráfico y los retrasos están altísimamente correlacionados.

Experimentos y Ajustes Adicionales

Variación del parámetro en KNN (K=3)

Al reducir los vecinos analizados de 5 a 3, el Accuracy disminuyó del 64.0% al 62.3%. Demuestra que un K muy bajo vuelve al modelo hiper-sensible al ruido de los datos, mientras que K=5 logra un balance superior en la generalización.

Eliminación de variables redundantes

Se eliminó la variable *'DelayFromFreeFlowSpeed'* por su alta correlación. Sorprendentemente, el Accuracy cayó al 62%. Esto probó que aunque dos variables se comporten similar, en KNN pueden aportar matices únicos imprescindibles para la precisión.

Límites de escalabilidad computacional

Entrenar KNN con 2 millones de filas demandó cerca de 2 horas. Aplicar este modelo puramente basado en distancias geométricas al dataset original completo (33 millones) resultaría inviable sin infraestructuras de Big

Simulación de un Caso Nuevo

2

Severidad "Moderada"

Consenso entre Algoritmos

Se inyectó un registro sintético manual al sistema simulando condiciones realistas de alto estrés vial:

- Distancia afectada: Alta (3.0 millas)
- Retraso típico: 8.0 minutos
- Temporalidad: Viernes a las 18:00 (Hora Pico)

Tanto el modelo KNN como la Regresión Logística analizaron las métricas y concluyeron unánimemente en un **Nivel 2**. Esto refuerza la confianza en la lógica interna del modelo, demostrando que puede interpretar correctamente escenarios de la vida cotidiana.

Conclusiones

KNN es el algoritmo vencedor gracias a su agudeza para interpretar redes no lineales en la congestión de datos. Sin embargo, este grado de precisión tiene un costo computacional masivo.

Además, el desbalance inherente de las bases de datos (pocos accidentes nivel 4 comparados con el volumen general) impidió que cualquier modelo dominara la detección de escenarios críticos.

Visión Futura: Para el despliegue del dataset completo de 33M en ambientes de producción a tiempo real, se requiere migrar a arquitecturas como Random Forest o ensambles por gradiente (XGBoost).

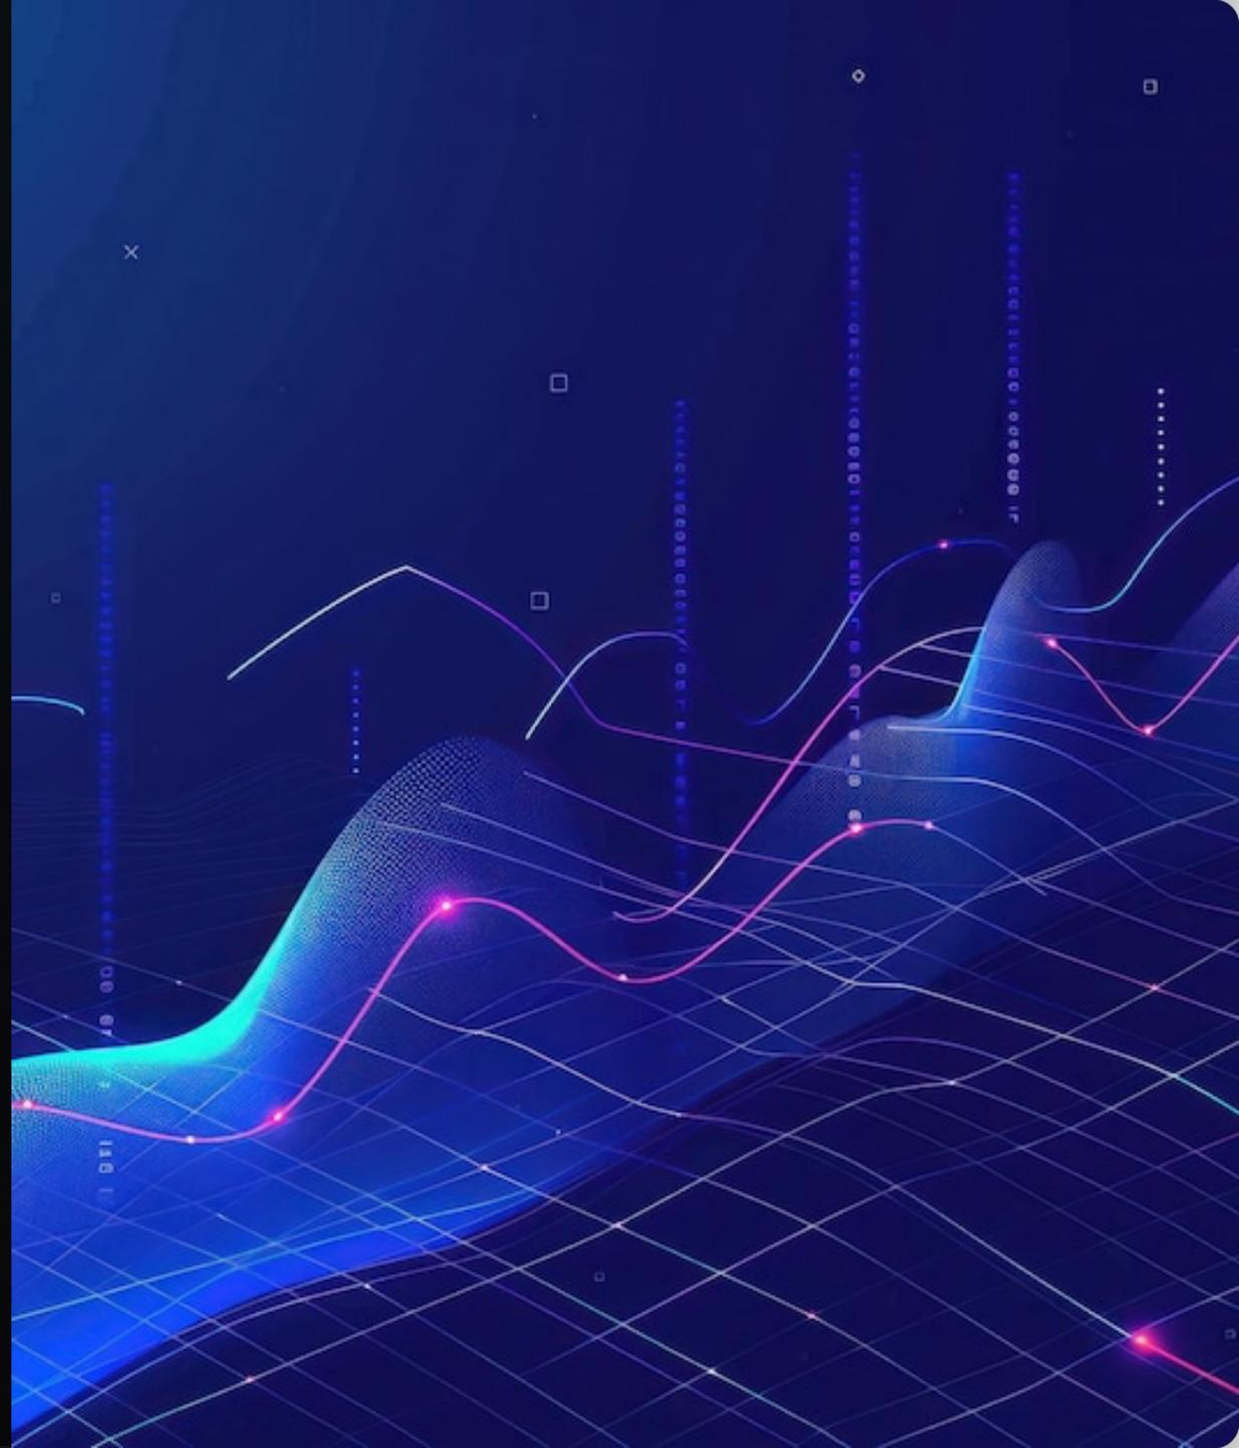

¿Preguntas?

Gracias por su atención al análisis del Entregable 2.

Image Sources

https://www.supplychainbrain.com/ext/resources/2023/12/07/USA-TRAFFIC-JAM-CARS-iStock--egdigital--140452002.webp?t=1702012400&width=1080

Source: www.supplychainbrain.com

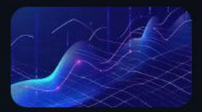

https://img.freepik.com/premium-photo/abstract-data-visualization-with-neon-lines-dark-blue-background_1247484-4186.jpg

Source: www.freepik.com