Taller Aplicado

Machine Learning con Privacidad Diferencial usando SmartNoise

Documento técnico

Dataset público de salud: Diabetes de Scikit-Learn

Clustering con K-Means y comparación original vs. protegido

Estudiante / grupo	Ainoa Bolea Villa, Santiago González Garzon, Mateo Giraldo Soto y Juan José Vélez Mejía
Asignatura	Machine Learning
Herramientas	Python, Pandas, Scikit-Learn, SmartNoise/OpenDP
Fecha	13/05/2026

Índice

1. Introducción **2**

2. Dataset seleccionado **2**

3. Variables sensibles **2**

4. Aplicación de privacidad diferencial **3**

5. Clustering **3**

6. Resultados **4**

7. Comparación visual **4**

8. Interpretación **7**

8.1. ¿El ruido destruyó completamente los patrones? 7

8.2. ¿Qué tanto cambió el clustering? 7

8.3. ¿Qué se perdió? 7

8.4. ¿Qué se protegió? 7

8.5. ¿Vale la pena sacrificar precisión por privacidad? 7

9. Relación con Machine Learning real **7**

10. Conclusiones **8**

Referencias **8**

1. Introducción

Este documento presenta la solución del taller aplicado de Machine Learning con privacidad diferencial. El objetivo es proteger variables sensibles antes de ejecutar un modelo de clustering y analizar el impacto del ruido sobre los resultados. Se trabaja con un dataset público de salud, debido a que este tipo de información requiere protección especial por su posible relación con condiciones personales y clínicas.

La privacidad diferencial permite modificar datos individuales mediante mecanismos matemáticos de ruido, reduciendo el riesgo de exposición o reidentificación sin destruir completamente el valor analítico del conjunto de datos. En este caso, se compara el comportamiento de un modelo de clustering antes y después de aplicar ruido diferencial a variables sensibles.

2. Dataset seleccionado

Se utilizó el dataset *Diabetes* disponible en Scikit-Learn. El conjunto contiene 442 registros y variables numéricas relacionadas con edad, sexo, índice de masa corporal, presión arterial, colesterol y glucosa, además de una variable objetivo de progresión de enfermedad.

Este dataset cumple con los requisitos del taller porque:

- Tiene más de 100 registros.
- Está compuesto por variables numéricas.
- Contiene información susceptible de privacidad.
- Permite realizar análisis exploratorio, protección de variables y clustering.

Aunque se trata de un dataset público y previamente anonimizado, representa un escenario útil para simular cómo se protegerían datos clínicos o personales antes de alimentar modelos de Machine Learning.

3. Variables sensibles

Las variables sensibles seleccionadas fueron edad, índice de masa corporal, presión arterial y glucosa. Estas variables fueron elegidas porque pueden revelar información sobre el estado de salud de una persona. En un escenario real, su exposición directa podría facilitar perfilamiento, discriminación, inferencias médicas o intentos de reidentificación.

- **Edad:** puede ayudar a identificar grupos poblacionales específicos.
- **Índice de masa corporal:** puede revelar condiciones de salud asociadas al peso.
- **Presión arterial:** puede indicar riesgos cardiovasculares.
- **Glucosa:** puede relacionarse con condiciones metabólicas o diabetes.

Proteger estas variables es importante porque, aunque no incluyan nombres o documentos de identidad, pueden combinarse con otros datos y aumentar el riesgo de inferencias sensibles.

4. Aplicación de privacidad diferencial

Se aplicó ruido Laplace a las variables sensibles. El mecanismo Laplace es común en privacidad diferencial porque permite modificar los valores individuales manteniendo tendencias agregadas. Se usó $\epsilon = 1{,}0$ y sensibilidad igual a 0,15.

El parámetro ϵ controla el equilibrio entre privacidad y utilidad:

- Un ϵ bajo aumenta la privacidad, pero también incrementa la pérdida de precisión.
- Un ϵ alto conserva más utilidad, pero protege menos los datos individuales.

En este taller, el ruido se agregó sobre las variables sensibles para observar si el modelo de clustering seguía encontrando patrones generales sin utilizar exactamente los valores originales.

5. Clustering

Se aplicó K-Means con 3 clusters sobre dos versiones del dataset:

1. Dataset original.
2. Dataset protegido con ruido diferencial.

Antes de entrenar el modelo, las variables fueron normalizadas con `StandardScaler` para evitar que diferencias de escala afectaran las distancias utilizadas por K-Means. Esta normalización es necesaria porque el algoritmo agrupa los datos según la distancia entre observaciones.

La metodología aplicada fue la siguiente:

1. Cargar el dataset.
2. Realizar análisis exploratorio.
3. Seleccionar variables sensibles.
4. Aplicar ruido diferencial.
5. Normalizar los datos originales y protegidos.
6. Ejecutar K-Means en ambos datasets.
7. Comparar métricas y visualizaciones.

6. Resultados

La Tabla 1 resume las principales métricas obtenidas en la comparación entre el dataset original y el protegido.

Cuadro 1: Métricas principales del experimento

Métrica	**Valor**
Silhouette original	0.1960
Silhouette protegido	0.1327
ARI original vs. protegido	0.5165
Varianza explicada PCA	0.5899

En el dataset original los clusters quedaron distribuidos como $\{0 : 141, 1 : 196, 2 : 105\}$. En el dataset protegido la distribución fue $\{0 : 101, 1 : 154, 2 : 187\}$. Esto muestra que el ruido cambió algunas asignaciones, pero no impidió que el modelo formara grupos.

El Silhouette Score disminuyó después de aplicar privacidad diferencial, lo cual indica que los clusters protegidos quedaron menos separados que los originales. Sin embargo, la estructura general no desapareció completamente.

7. Comparación visual

Las siguientes figuras muestran la separación de clusters proyectada con PCA en dos dimensiones. PCA se usa para reducir la dimensionalidad del dataset y poder observar gráficamente

la distribución de los grupos.

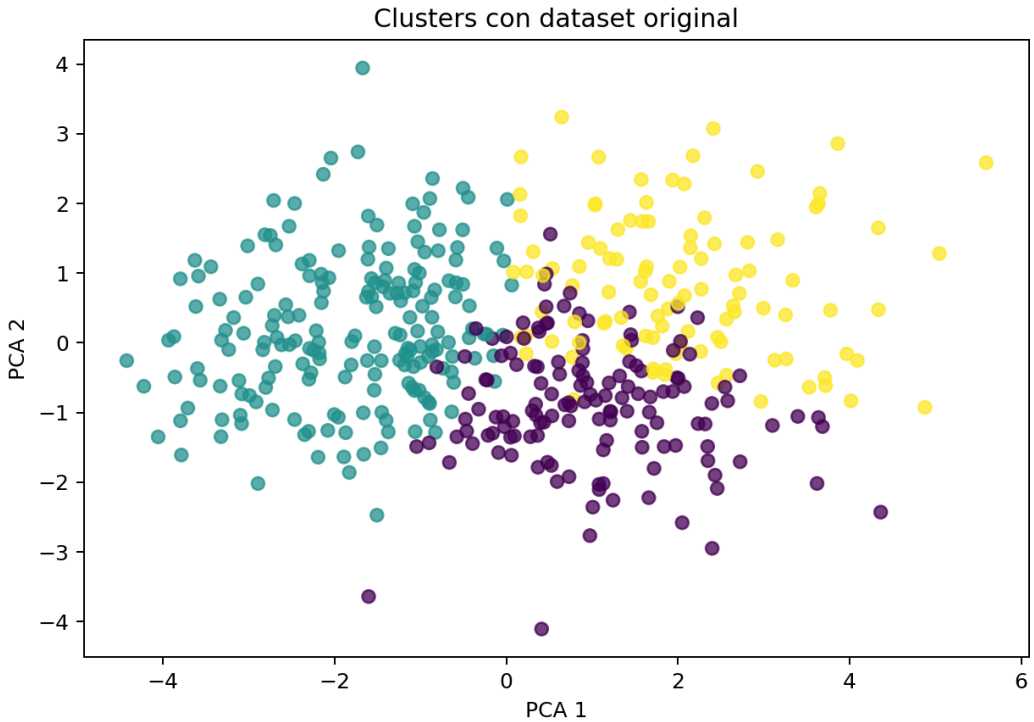

Figura 1: Clusters con dataset original.

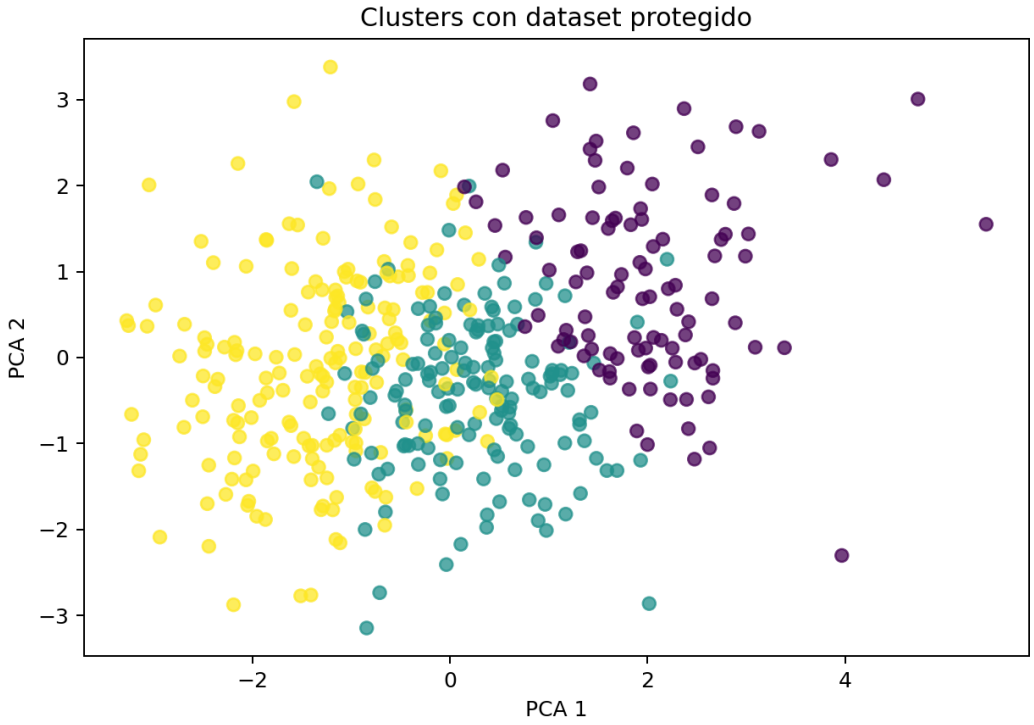

Figura 2: Clusters con dataset protegido.

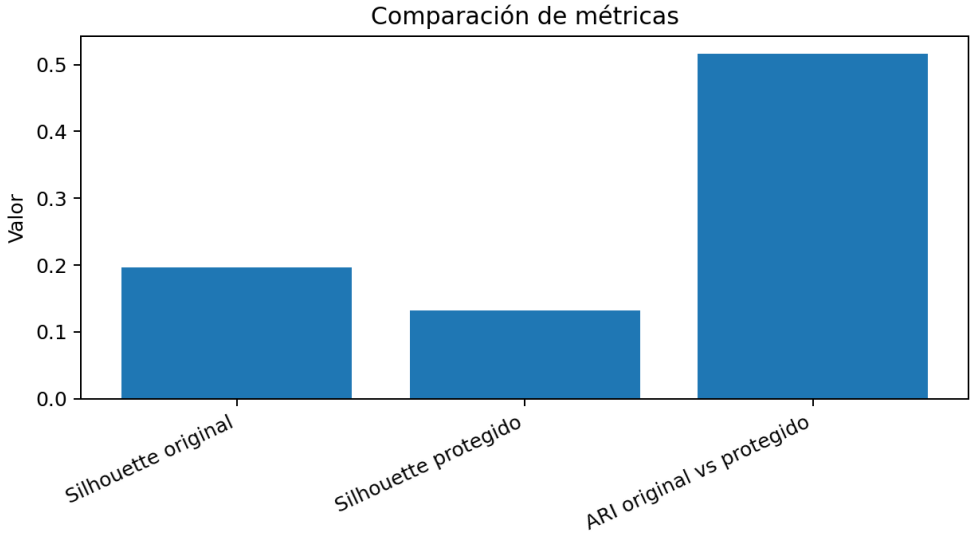

Figura 3: Comparación de métricas principales.

Visualmente, el dataset protegido conserva una agrupación general, pero con mayor mezcla entre puntos. Esto es coherente con la reducción del Silhouette Score, ya que el ruido modifica distancias entre registros y puede mover algunas observaciones hacia otros grupos.

8. Interpretación

8.1. ¿El ruido destruyó completamente los patrones?

No. Los clusters se conservaron parcialmente, aunque algunas asignaciones cambiaron. Esto indica que el ruido diferencial no eliminó por completo la estructura de los datos.

8.2. ¿Qué tanto cambió el clustering?

Cambió de forma moderada. El ARI obtenido fue 0.5165, lo que permite medir la estabilidad frente al clustering original. Un ARI igual a 1 indicaría coincidencia perfecta, mientras que valores cercanos a 0 indicarían poca similitud. Por tanto, el resultado muestra que hubo cambios, pero también cierta conservación de patrones.

8.3. ¿Qué se perdió?

Se perdió precisión individual, porque algunos valores sensibles fueron alterados y algunos registros pueden pasar a otro cluster. También se redujo la separación entre grupos, lo cual se refleja en el menor Silhouette Score del dataset protegido.

8.4. ¿Qué se protegió?

Se protegieron variables clínicas sensibles, reduciendo la exposición de valores exactos. Esto disminuye el riesgo de que una persona sea perfilada o identificada a partir de características relacionadas con su salud.

8.5. ¿Vale la pena sacrificar precisión por privacidad?

Sí, especialmente en salud, gobierno, educación y fintech, donde proteger a las personas es más importante que conservar exactitud individual absoluta. El sacrificio de precisión puede ser aceptable si el análisis conserva tendencias generales y reduce riesgos de privacidad.

9. Relación con Machine Learning real

En producción, la privacidad diferencial permite construir análisis y modelos reduciendo riesgos de reidentificación. Esto es importante para cumplir principios de protección de datos

como GDPR y Habeas Data. También fortalece la inteligencia artificial ética, porque permite equilibrar utilidad analítica con respeto por la privacidad de las personas.

En contextos reales, esta técnica puede aplicarse antes de generar reportes, entrenar modelos o compartir datasets entre áreas de una organización. Por ejemplo:

- En salud, permite analizar tendencias clínicas sin exponer valores exactos de pacientes.
- En gobierno, ayuda a publicar estadísticas sin revelar información ciudadana específica.
- En fintech, reduce el riesgo de exposición de ingresos, consumos o comportamientos financieros.
- En educación, protege resultados académicos o datos personales de estudiantes.

De esta forma, la privacidad diferencial no solo es una técnica matemática, sino también una práctica de responsabilidad ética en proyectos de inteligencia artificial.

10. Conclusiones

- La privacidad diferencial permitió proteger variables sensibles sin eliminar por completo el valor analítico del dataset.
- El clustering sobre datos protegidos mantuvo una estructura general, aunque con cambios en algunas asignaciones.
- El parámetro ϵ es clave para equilibrar privacidad y precisión.
- En escenarios reales, la pérdida parcial de exactitud puede ser aceptable cuando se trabaja con información personal o clínica.
- La comparación original vs. protegido demuestra que sí es posible aplicar Machine Learning preservando parcialmente la privacidad de los datos.

Referencias

- Dwork, C., & Roth, A. (2014). *The Algorithmic Foundations of Differential Privacy.*
- Scikit-learn developers. (2026). *Diabetes dataset and clustering documentation.*
- OpenDP / SmartNoise Project. (2026). *Differential privacy tools for Python.*