Análisis Exploratorio de Datos y Modelado Predictivo

Dataset Palmer Penguins · EDA, Regresión Lineal y Regresión Logística

Análisis Exploratorio

Regresión Lineal

Regresión Logística

Made with GAMMA

El Dataset

Palmer Penguins

El dataset reúne mediciones físicas de tres especies de pingüinos observados en la Antártida, y es ampliamente usado como referencia en ciencia de datos y aprendizaje automático.

333 observaciones disponibles tras la limpieza de datos.

Longitud del pico

bill_length_mm

Profundidad del pico

bill_depth_mm

Longitud de la aleta

flipper_length_mm

Masa corporal

body_mass_g

Especie

Adelie / Gentoo / Chinstrap

Made with GAMMA

Preprocesamiento

Limpieza de Datos

Antes de cualquier análisis, se identificaron y eliminaron las filas con valores faltantes usando `dropna()`, garantizando la integridad del conjunto de datos.

Variables morfológicas

`bill_length_mm`, `bill_depth_mm`, `flipper_length_mm`, `body_mass_g` — **2 valores faltantes** cada una

Variable de sexo

`sex` — **11 valores faltantes**, la variable con mayor proporción de datos incompletos

344	11	333
Registros originales	Filas eliminadas	Registros finales

Made with GAMMA

EDA

Distribución de Especies

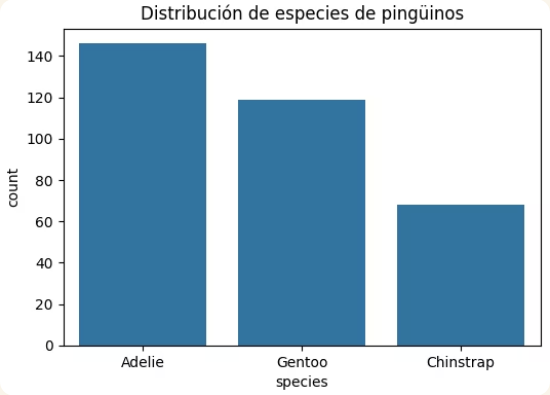

Las tres especies están representadas en el dataset, aunque con proporciones distintas. **Adelie** domina con 152 registros, seguida de **Gentoo** con 124 y **Chinstrap** con 68.

Esta distribución desbalanceada es un factor a considerar al entrenar y evaluar los modelos de clasificación.

Made with GAMMA

EDA

Distribución de Masa Corporal

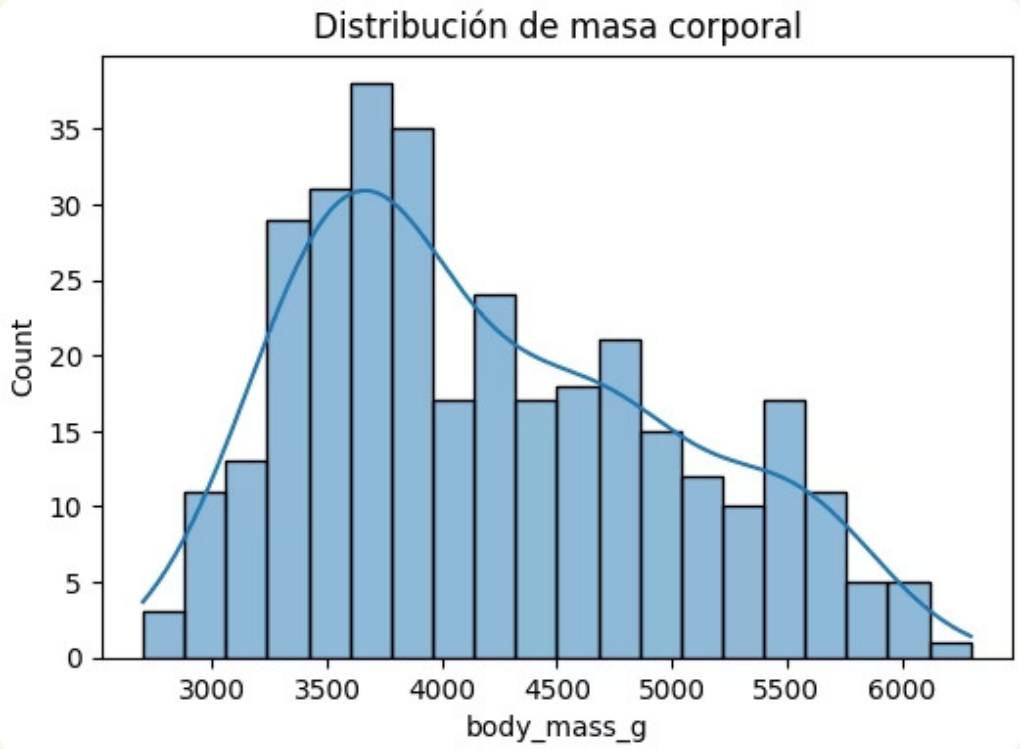

El histograma de `body_mass_g` revela una distribución amplia. La mayoría de los individuos se concentra entre **3,500 y 5,000 gramos**, con algunos ejemplares alcanzando cerca de los 6,300 g.

Esta variabilidad refleja diferencias físicas entre individuos y, muy probablemente, entre las distintas especies del dataset.

Made with GAMMA

EDA

Correlación entre Variables

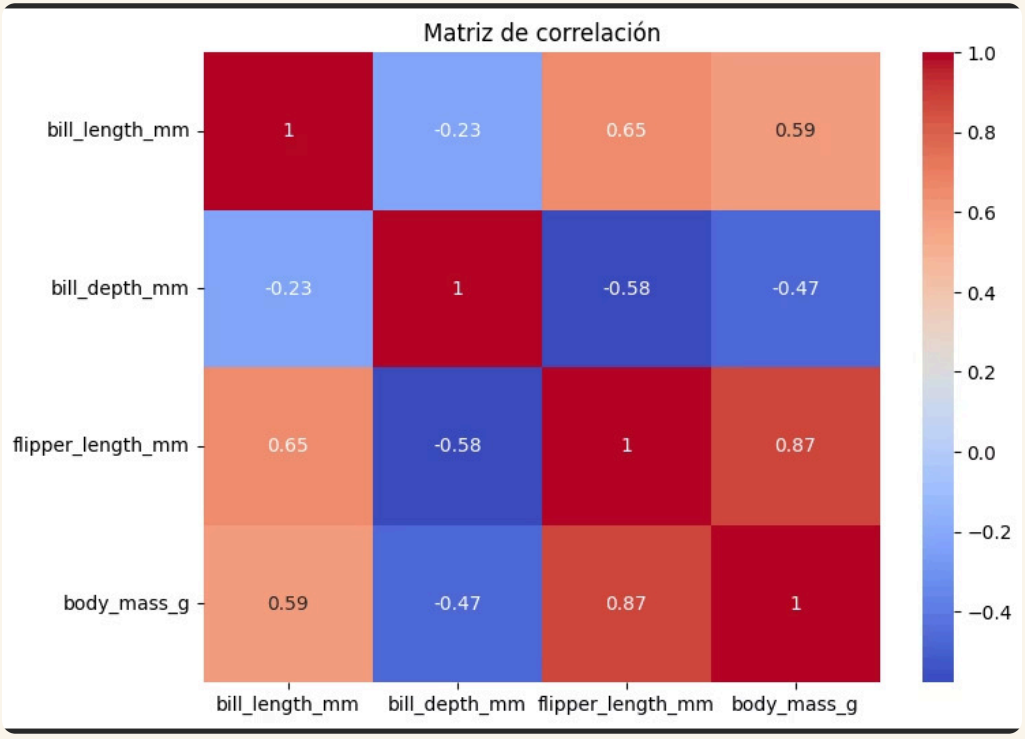

Se calculó una matriz de correlación entre las cuatro variables numéricas del dataset para identificar relaciones relevantes.

Correlación clave: flipper_length_mm y body_mass_g presentan una correlación positiva fuerte de **r = 0.87**.

Este hallazgo indica que los pingüinos con aletas más largas tienden a tener mayor masa corporal, y sirvió como base para seleccionar las variables del modelo de regresión lineal.

Made with GAMMA

Modelado

Regresión Lineal: Predicción de Masa Corporal

Objetivo: Predecir `body_mass_g` a partir de características físicas del pingüino.

Variables predictoras

`flipper_length_mm` · `bill_length_mm`

$R^2 \approx 0.76$

El modelo explica el 76% de la variabilidad en la masa corporal

MSE ≈ 143,782

Error cuadrático medio del modelo sobre el conjunto de prueba

Interpretación

Un R^2 de 0.76 indica una capacidad predictiva sólida. Las variables morfológicas seleccionadas capturan gran parte de la información necesaria para estimar el peso de un pingüino.

Made with GAMMA

Modelado

Regresión Logística: Clasificación de Especies

Objetivo: Clasificar la especie del pingüino usando sus características físicas como predictores.

→ Variables utilizadas

`bill_length_mm`, `bill_depth_mm`, `flipper_length_mm`

→ Accuracy = 1.0 (100%)

Todas las observaciones del conjunto de prueba fueron clasificadas correctamente.

→ Matriz de confusión perfecta

Sin falsos positivos ni falsos negativos en ninguna de las tres clases.

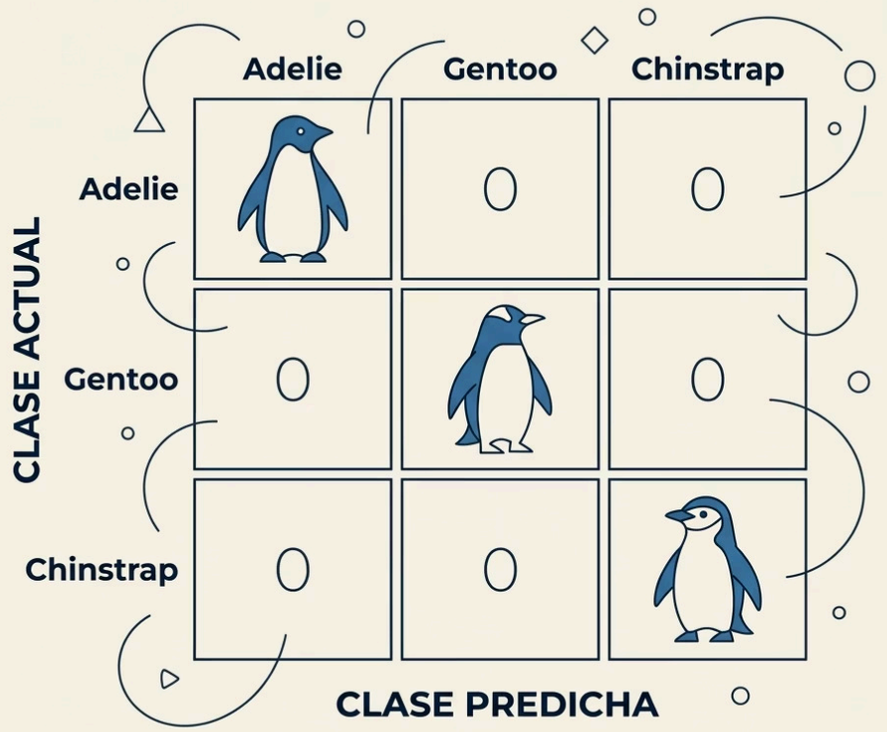

Matriz de confusión perfecta para tres clases: Adelie, Gentoo y Chinstrap. Todas las predicciones son correctas: Adelie clasificada cente, Gentoo clasificada correctamente, Chinstrap clasificada correctamente. Accuracy total del 100%.

Made with GAMMA

Cierre

Conclusiones

Correlación fuerte

La longitud de la aleta y la masa corporal presentan una correlación de **r = 0.87**, la más alta del dataset.

Regresión lineal efectiva

El modelo predice la masa corporal con un **R^2 de 0.76**, demostrando buena capacidad predictiva.

Clasificación perfecta

La regresión logística clasifica las especies con **100% de exactitud** usando solo tres variables morfológicas.

Conclusión general

Las características físicas de los pingüinos contienen información suficiente para predicción y clasificación con alto desempeño.