

Machine Learning con Privacidad Diferencial

Julian Gomez Posada – Laura Posada – Samuel Gil lopez

Aplicación de **SmartNoise** / **OpenDP** al análisis de datos de salud, usando el *Stroke Prediction Dataset*.

- Objetivo: aprender a proteger datos sensibles con **privacidad diferencial** sin destruir la utilidad analítica
- Herramienta: **SmartNoise** / **OpenDP** — framework open-source de Microsoft para privacidad diferencial
- Dataset: **Stroke Prediction Dataset** — variables clínicas y demográficas

Dataset y Contextualización

Stroke Prediction Dataset

Este conjunto de datos se utiliza para predecir la probabilidad de que un paciente sufra un accidente cerebrovascular, basándose en parámetros como el sexo, la edad, diversas enfermedades y el tabaquismo. Cada fila de los datos proporciona información relevante sobre el paciente.

- `id`: identificador único.
1. `gender`: género (Male, Female, Other).
 2. `age`: edad del paciente.
 3. `hypertension`: 0 si el paciente no tiene hipertensión, 1 si el paciente tiene hipertensión.
 4. `heart_disease`: 0 si el paciente no tiene ninguna enfermedad cardíaca, 1 si el paciente tiene una enfermedad cardíaca.
 5. `ever_married`: No o Yes.
 6. `work_type`: children, Govt_job, Never_worked, Private o Self-employed.
 7. `Residence_type`: Rural o Urban.
 8. `avg_glucose_level`: nivel promedio de glucosa en sangre.
 9. `bmi`: índice de masa corporal.
 10. `smoking_status`: formerly smoked, never smoked, smokes o Unknown.
 11. `stroke`: 1 si el paciente tuvo un accidente cerebrovascular, 0 si no.

Imagen de los primeros 5 registros originales del dataset

	id	gender	age	hypertension	heart_disease	ever_married	work_type	Residence_type	avg_glucose_level	bmi	smoking_status	stroke
0	9046	Male	67.0	0	1	Yes	Private	Urban	228.69	36.6	formerly smoked	1
1	51676	Female	61.0	0	0	Yes	Self-employed	Rural	202.21	NaN	never smoked	1
2	31112	Male	80.0	0	1	Yes	Private	Rural	105.92	32.5	never smoked	1
3	60182	Female	49.0	0	0	Yes	Private	Urban	171.23	34.4	smokes	1
4	1665	Female	79.0	1	0	Yes	Self-employed	Rural	174.12	24.0	never smoked	1

Preparación y Limpieza de Datos

Pasos de limpieza



- **Valores faltantes:** imputación de BMI con la mediana

	nulos	porcentaje_%
bmi	201	3.93

- **Winsorización:** reducción de outliers en variables numéricas
- **Eliminación del identificador** directo (id)

La limpieza es crítica: los outliers distorsionan el ruido diferencial y degradan la calidad del clustering.

 para mejor visualización abre la imagen con un click



Variables Sensibles y Privacidad Diferencial

Variables sensibles identificadas

- **age** — edad del paciente
- **bmi** — índice de masa corporal
- Se elimina **id** como identificador directo

¿Qué es la privacidad diferencial?

Marco matemático que **añade ruido estadístico controlado** para garantizar que ningún individuo sea identificable. El **mecanismo gaussiano** inyecta ruido con desviación estándar σ .



 **id**: es **identificador directo**; la protección adecuada es **no publicarlo ni usarlo en modelado** (no sumarle ruido al código). En `df_limpio` la columna **id** **ya fue eliminada** en la limpieza.

- **age** (**edad**): **cuasi-identificador** muy fuerte; combinada con sexo, trabajo o tabaquismo reduce mucho el anonimato. Es **numérica** → encaja con el **mecanismo Gaussiano** de OpenDP (SmartNoise)
- **bmi** (**índice de masa corporal**): dato **antropométrico / clínico** sensible; puede relacionarse con estigma o inferencias de salud. Tras la limpieza está **sin nulos**, en rango acotado por winsorización, y sigue siendo **numérica** → también admite ruido aditivo.
- **smoking_status**: es **sensible** pero **categorica**; el esquema actual del notebook aplica ruido columna a columna sobre **números**.

Aplicación de SmartNoise / OpenDP



RMSE (limpio vs perturbado) por sigma y columna:

columna	age	bmi
---------	-----	-----

sigma		
-------	--	--

0.25	0.2497	0.2486
------	--------	--------

0.50	0.4989	0.4988
------	--------	--------

1.00	1.0071	0.9961
------	--------	--------

2.00	2.0018	1.9984
------	--------	--------


El parámetro sigma (σ)

- **σ alto** → más ruido → mayor privacidad, menor precisión
- **σ bajo** → menos ruido → más precisión, menor privacidad
- Se probaron múltiples valores para observar el trade-off

Comparación de variables originales vs privadas

La curva **azul** es siempre `df_limpio`; la **naranja** es la misma columna tras aplicar el **mecanismo Gaussiano de OpenDP**. Al subir σ , la distribución naranja se **ensancha** y **suaviza** picos del azul: se pierde detalle fino (más privacidad visual) pero se mantiene en gran medida la forma global.


`age`: con σ pequeño, azul y naranja casi coinciden. Con σ grande, el naranja **difumina** los picos de edad y puede aparecer masa fuera del rango original, típico del ruido aditivo sin recorte posterior. Los **boxplots** suelen seguir parecidos en mediana e IQR mientras el ruido sea moderado; los bigotes más largos u outliers en el naranja, es la dispersión extra del ruido.




Comparación de variables originales vs privadas

bmi: el azul refleja la forma ya “marcada” por la limpieza. El naranja **aplana** esos picos al aumentar σ : se enmascara mejor **quién** tenía exactamente esos valores. Con σ alto pueden salir **outliers** nuevos en el boxplot (valores extremos por el ruido), aunque el centro del recuadro cambie poco.

Para elegir `sigma_elegido`: Se busca el **mayor** σ en el que aún parezca aceptable la utilidad (forma razonable del naranja, boxplots no “explosionados”) antes de pasar a clustering. Se escogió $\sigma=1$



Clustering con K-Means



- Se aplicó **K-Means** sobre las variables age y bmi
- Número de clusters: **k = 6**, seleccionado mediante el método del codo y silhouette score
- El **silhouette score** mide la cohesión y separación de los clusters


Clustering Limpio vs. Privado

Métrica	Datos limpios	Datos privados																								
Silhouette Score	0.3701	0.3258																								
Diferencia	-0.0442	tras el ruido gaussiano en <code>age</code> y <code>bmi</code> , los grupos quedan algo menos cohesionados/separados en promedio en el espacio escalado, lo cual es coherente con una ligera deformación de la geometría que usa K-Means.																								
NMI entre particiones	0.8206	Mide cuánto se parecen las dos particiones sobre las mismas filas (mismos pacientes en el mismo orden), sin importar cómo se numeren los clusters. Un valor alto implica que, a nivel global, muchas decisiones de agrupación se mantienen alineadas entre limpio y privado, aunque los tamaños de cluster cambien.																								
Pacientes por cluster	<table><tr><td>0</td><td>2197</td></tr><tr><td>1</td><td>440</td></tr><tr><td>2</td><td>249</td></tr><tr><td>3</td><td>229</td></tr><tr><td>4</td><td>381</td></tr><tr><td>5</td><td>1614</td></tr></table>	0	2197	1	440	2	249	3	229	4	381	5	1614	<table><tr><td>0</td><td>1683</td></tr><tr><td>1</td><td>150</td></tr><tr><td>2</td><td>249</td></tr><tr><td>3</td><td>701</td></tr><tr><td>4</td><td>79</td></tr><tr><td>5</td><td>2248</td></tr></table>	0	1683	1	150	2	249	3	701	4	79	5	2248
0	2197																									
1	440																									
2	249																									
3	229																									
4	381																									
5	1614																									
0	1683																									
1	150																									
2	249																									
3	701																									
4	79																									
5	2248																									

- la distribución de pacientes **sí cambia** entre versiones, eso refleja que muchos puntos **crusan fronteras** entre centroides al moverse `age` y `bmi`. El cluster **4** en el privado queda **muy pequeño (79)**: conviene interpretarlo como grupo poco numeroso, sensible al ruido o a la posición de centroides. El hecho de que el cluster **2** tenga **249** pacientes en ambos casos puede ser **coincidencia** de tamaño; no implica por sí solo que sean exactamente los mismos individuos.
- con $\sigma = 1$ y $k = 6$, se observa un **trade-off típico**: algo de **pérdida de calidad métrica** (silhouette) y **redistribución** de masas entre clusters, pero una **alta similitud** entre particiones (NMI), coherente con proteger dos variables numéricas sensibles sin destruir del todo el agrupamiento obtenido en limpio.

Visualización e Interpretación Final

Comparación visual (proyección edad-IMC): K-Means usa todas las columnas numéricas; el solape es esperable en 2D.




Al añadir ruido DP en `age` y `bmi`, los centroides se **desplazan** y muchos puntos **cambian de etiqueta**.

Visualización e Interpretación Final

Boxplots por variable: leen la distribución **marginal** de cada variable **dentro de cada etiqueta** de cluster.

- **age y bmi:** en **df_privado** esas columnas **sí** llevan el mecanismo gaussiano; además, al cambiar las asignaciones, los boxplots por cluster combinan **dos efectos**: valores perturbados y **nueva composición** de cada grupo.
- **avg_glucose_level:** en este taller **no** se aplica ruido DP a la glucosa; **fila a fila** debería ser **igual** que en **df_limpio**. Si los boxplots de glucosa **cambian de forma** entre columnas, la causa principal es la **reasignación de clusters** (mismas glucosas, distinto «cajón»), no que el DP haya alterado directamente la glucosa.



Interpretaciones

1. ¿El ruido destruyó completamente los patrones?

No. El **silhouette** baja de **0,3701** (limpio) a **0,3258** (privado), es decir $\approx -0,044$: hay algo menos de separación/cohesión media en el espacio escalado, pero no un colapso. El **NMI** entre particiones es $\approx 0,82$, alto: a nivel global muchos pacientes siguen “cerca” de la misma agrupación relativa aunque cambien etiquetas y tamaños de cluster. .

2. ¿Qué tanto cambió el clustering?

Moderadamente en métrica global y **mucho** en etiquetas y tamaños: el **silhouette** cae poco, pero los **conteos por cluster** se **redistribuyen**, un mismo perfil puede ser “cluster 5” en limpio y “cluster 0” en privado.

3. ¿Qué se perdió?

Precisión en **edad e IMC** (valores exactos y fronteras entre grupos que dependían de esas dos dimensiones), y **estabilidad de la etiqueta** de cluster para muchas filas. .

4. ¿Qué se protegió?

La fila de `df_privado` oculta mejor los **valores reales** de **edad e IMC**.

5. ¿Vale la pena sacrificar precisión por privacidad?

Depende del uso, pero en **este experimento** la respuesta es **sí, con matices**. En salud, compartir microdatos sin salvaguardas expone a personas y a la institución; la DP en `age` y `bmi` es una forma explícita de **reducir filtración** de atributos muy identificables. Aquí, con $\sigma = 1$, el coste medido es **acotado** (**silhouette** $\approx -0,044$) y la partición sigue **bastante alineada** con la del limpio (**NMI** $\approx 0,82$), lo que sugiere que **sí** puede valer la pena para **exploración, comunicación de agregados o pipelines internos** donde no se tomen decisiones clínicas individuales solo con etiquetas de cluster en `df_privado`.

Relación con Machine Learning real

En producción, los datos de **salud** suelen tratarse como **personales y sensibles**: cualquier tablero, informe o modelo entrenado sobre **filas** puede filtrar atributos si no hay controles técnicos y de proceso.

- **GDPR (UE)**: exige licitud, minimización y medidas técnicas razonables; publicar o compartir microdatos sin salvaguardas choca con el principio de **integridad y confidencialidad**. Una versión como `df_privado` documenta que se **limitó la exactitud** de edad/IMC antes del clustering, en la línea de *privacy by design* y de poder **argumentar** el tratamiento frente a interesados o autoridades.
- **Habeas Data (Colombia / América Latina)**: el tratamiento de datos sensibles en salud exige finalidades claras y seguridad; filtrar **edad o IMC exactos** puede afectar la **intimidad** o facilitar **encruzamiento** con otras bases. El ruido gaussiano reduce la **inferencia puntual** sobre esas columnas en la tabla compartida o derivada.
- **Salud (caso del taller)**: además del DP en edad/IMC, en el flujo se **eliminó id** y se hizo **limpieza** (imputación y winsorización) por utilidad estadística; el **clustering** siguió usando **todas** las numéricas, pero solo dos fueron perturbadas, lo que es típico en pilotos: **proteger lo más identificable** y mantener el resto bajo control de acceso.
- **Gobierno y fintech**: el mismo patrón aparece en **censos, tasas o scoring**: difundir valores casi exactos de variables sensibles aumenta riesgo de **reidentificación** o de exposición de **outliers**; la DP (u otros controles) se negocia frente a la **precisión** de agregados o modelos.
- **Inteligencia artificial ética**: conviene **transparentar** qué columnas se ruidizan, con qué σ (o ϵ/δ si aplica), y cómo cambian resultados (como aquí con **k = 6** y la comparación limpio/privado). Eso alinea la IA con **explicabilidad del riesgo**, no solo con la precisión del modelo.

CONCLUSIONES

Conclusiones y Trabajo Futuro



Protección garantizada

La privacidad diferencial protege datos sensibles sin eliminar la utilidad analítica.



Equilibrio alcanzado

SmartNoise/OpenDP permite controlar el trade-off entre privacidad y precisión mediante σ .



Patrones preservados

El clustering mantiene estructura global pese al ruido añadido.